

Diffussion Model

- jensen's inequality: 함수 안에 넣기
- intractability: 다루기 힘들 Tractability: 다루기 쉬움
- 생성모델 종류&특징: diffusion model은 간단히는 는 좀 느리다(cf. 삼각형)(why 1000번과정이라-마르코프 체인(전단계에 얽히는)) vs. DDIM: 마르코프 체인 굳이 안써서 굳이 막 전단계에 얽히지 않아.

- 생성모델 구분

-명백: VAE, Diffussion Model

-명백x: GAN

- GAN의 이해: 명백x, 확실x, 어쩌다 보니 잡혔다(생성자, 판별자)..(확률적으로 확률이 적다)
- VAE의 이해: 명백한 모델, px와 z로 하려다가 안돼서 qz 인코더를 달았다. 그래서 qz와 z와 왔다갔다하면 px를 근사할 수 있을거다

- 가우시안의 중요도: 분포를 가정할때는 가우시안이라하기 Diffusion할때
- Forward: 이미지에서 노이즈 더함 가우시안의 형태로 (학습x, 그냥 노이즈 더하는 것)
- Reverse: 노이즈를 덜어내는 것(학습o) 가우시안 형태로
- 세타 있으면 학습하는 모델표시 reverse는 학습하니까 세타 있는거!

Unet 쓰는 이유 노이즈가 더는 과정인데 이때 UNet이 이걸 잘한다..근데 요즘에는 안씀

$$p_{\theta}(x_{t-1}|x_t)$$

- 아래는 DDPM loss 중요부분만 필기
- $$= \mathbb{E}_{1:\tau \sim q(x_{1:\tau}|x_0)} \left[-\log p_{\theta}(x_{\tau}) - \sum_{t=1}^T \log \frac{p_{\theta}(x_{t-1}|x_t)}{q(x_t|x_{t-1})} \right]$$

노란색 부분에 t=1 를 대입하고 그 부분만 따로 뺐다. 그러니 두번째 텀은 t=2 로 바뀌고, 세 번째 텀이 생겼다.(왜 굳이 이러냐 전개 하고싶으니)

$$Loss_{Diffusion} = D_{KL}(q(x_T|x_0)||p_\theta(x_T)) + \sum_{t=2} D_{KL}(q(x_{t-1}|x_t, x_0)||p_\theta(x_{t-1}|x_t)) + E_q \log p_\theta(x_0|x_1)$$

:결국 구한 것에서 초록색 부분만 사용한다 우리는

$$\sum_{t=2} D_{KL}(q(x_{t-1}|x_t, x_0)||p_\theta(x_{t-1}|x_t)) \text{ 여기서 모델에게 맡기지 않는 loss term 즉,}$$

$$q(x_{t-1}|x_t, x_0)$$

이 부분만 구하면 되는데 이는 가우시안이니까 정규화 시키면 평균(뮤)를 구하면 된다.

수식을 통해 계산해서 구하면 됨 아래는 일부만 보여줌

신기하게도 PDF 과 같음!!!

$$N(x; \mu, \sigma^2) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

$$\frac{1}{\sqrt{2\pi\beta_t(\frac{1-\bar{\alpha}_{t-1}}{1-\bar{\alpha}_t})}} \exp\left(-\frac{1}{2\beta_t(\frac{1-\bar{\alpha}_{t-1}}{1-\bar{\alpha}_t})} \left[x_{t-1} - \left(\frac{\sqrt{\bar{\alpha}_{t-1}}\beta_t}{1-\bar{\alpha}_t} x_0 + \frac{\sqrt{\bar{\alpha}_t}(1-\bar{\alpha}_{t-1})}{1-\bar{\alpha}_t} x_t\right)^2\right]\right)$$

$$mean = a = \frac{\sqrt{\bar{\alpha}_{t-1}}\beta_t}{1-\bar{\alpha}_t} x_0 + \frac{\sqrt{\bar{\alpha}_t}(1-\bar{\alpha}_{t-1})}{1-\bar{\alpha}_t} x_t$$

$$var = b = \beta_t \left(\frac{1-\bar{\alpha}_{t-1}}{1-\bar{\alpha}_t}\right)$$

최종:

$$L_{simple}(\theta) := \mathbb{E}_{t, x_0, \epsilon} \left[\left\| \epsilon - \epsilon_\theta(\sqrt{\bar{\alpha}_t} x_0 + \sqrt{1-\bar{\alpha}_t} \epsilon) \right\|^2 \right]$$

ϵ

이게 즉 노이즈 실제 노이즈랑 예측한 노이즈 빼는 것이다.

결국 최종 정리

- $\mathbf{x}_t = \sqrt{\bar{\alpha}_t} \mathbf{x}_0 + \sqrt{1-\bar{\alpha}_t} \epsilon, \epsilon \sim \mathcal{N}(0, \mathbf{I})$ (Forward)
- $\beta_1 = 10^{-4}, \beta_T = 0.02$

- $\alpha_t := 1 - \beta_t, \bar{\alpha}_t := \prod_{s=1}^t \alpha_s$
- $\epsilon - \epsilon_\theta(\mathbf{x}_t) = \epsilon - \epsilon_\theta(\sqrt{\bar{\alpha}_t}\mathbf{x}_0 + \sqrt{1 - \bar{\alpha}_t}\epsilon)$ (Loss)
 - ϵ_θ = prediction network

여기서 애플론은 포워드 과정에서 완성된 전체 노이즈고 입실론 세타는 현재 단계 진행중인 단계의 노이즈

- $\mathbf{x}_{t-1} = \frac{1}{\sqrt{\alpha_t}} \left(\mathbf{x}_t - \frac{\beta_t}{\sqrt{1 - \bar{\alpha}_t}} \epsilon_\theta(\mathbf{x}_t, t) \right) + \sqrt{\tilde{\beta}_t} \epsilon, \epsilon \sim \mathcal{N}(0, \mathbf{I})$ (Reverse)
 - $\tilde{\beta}_t = \frac{1 - \bar{\alpha}_{t-1}}{1 - \bar{\alpha}_t} \beta_t$
 - $\tilde{\beta}_t = \beta_t$ 로 해도 성능차이 없음

++사람이 받아들이는 이미지와 인공지능이 받아들이는 이미지의 차이는 큼 기계는 노이즈가 더해지면 아예 뭔가 인식을 못함

++애플론은 계속 랜덤으로(포워드 과정에서)

참고 링크

stabilityai/stable-diffusion-xl-base-1.0 · Hugging Face

We're on a journey to advance and democratize artificial intelligence through open source and open science.

🤗 <https://huggingface.co/stabilityai/stable-diffusion-xl-base-1.0>

